

Big Data



1^{ère} génération

★ Data File
(DF)

→ Texte (CSV, XML, JSON...)
→ Binaire Parquet (c'est un fichier binaire performant et fiable)

2^{ème} génération

★ Data Base
(DB)

3^{ème} génération



★ Data Warehouse
(DW)

4^{ème} génération

★ Data Lake
(DL)

BigData كاندل في الـ PO و خلية في الـ PO
péca octet في

Big Data les 3 V



Hadoop Cluster Multi-Nodes
" " " " " " Single Node

Cloudera

sol° شركة تشر في الـ PO و الـ PO
hadoop
خافرة

Mongo DB
collection في الـ PO



- * Row-Store
- * Column-Store

* Si je traite des données non structurées
=> mon projet est ds le monde de big data

* Streaming
big data = 24x7x365
not go
ex: smart city

Sandbox

VM
les logiciels
hadoop, spark, ...
installés

minimum
10 Go de RAM

Cloudera Sandbox

2ème méth pr savoir si c un projet big data :

un projet classique
structure classique
=> projet big data

Linux Apache MySQL PHP
LAMP Stack

la nouvelle pile de développement
=> **MEAN** Stack
MERN Stack

Comparse GUI

* télécharger
mongo db

rien chose pr
Spark

hadoop
Soit je l'installe
Soit je fais un abonnement
ds cloudera

il ya d'autre V = Veracity, value, (fidelity, data, fake/true data)

- Volume** (cluster)
- Hadoop
 - Spark
 - MongoDB

Big Data

Variete

- Document (MongoDB)
- Graph (Neo4J)
- C-store (Hbase/any)
- Key-value (Redis)

Velocity

→ Kafka

Streaming (s'agit de flux en temps réel)
(s'agit de flux en temps réel)


* **Sharding**
Noms de clusters




Schema On Read ≠ Schema On Write
(P. 108 et 109)

8.1.2.1 (p. 108)



Schema-on-read




Schema-on-write



BD cloud
redshift
BD quite
column



programme
communiqué avec le serveur



4 types de clients

Installer

Mongo DB

Shell (Desktop)

↳ Mongo Sh

GUI + Desktop

↳ Compass

ds cmd Admin on tape mongosh

show databases; on va trouver des BD par défaut

SGLD

Système Gestion Lake de Données


il peut gérer plusieurs BD au même temps contrairement à Oracle etc...

SQL Server et Mongo DB) => multi data base
containing à d'autres systèmes comme Oracle

etel etel
best m0 amok

Table
Produits

Collection




1000000

ORM
Object Relational Mapping

DB relationnel / Java langage Orienté Objet

ليس يفهم بعضه لازم
مترجم كاني هو ORN

Mongo DB Langage



Pipeline
 commande paramètre les les
 commandes
 c1 (c2 (c3 (...)))

use L3DSI2

(il va automatiquement créer la base si elle n'existe pas)

Insert ---
 Into ---
 Values ---

ds mongo db la forme
 de la commande ~~insert~~
Insert ~~insert~~

← commonCase
 db.etudiants.insertOne({id_etu: 1, Nom: 'Ahmed'})

مايوس بريس
 minus 19
 mais si j'ai nommé la collection
 avec 'E' mais je l'écris avec 'e'
 pr lui c'est une autre collection

db . Etudiants . insertOne ({id_etu: 1, Nom: 'Ahmed'})

pointeur DB collection commande Document

db . Etudiants . find() pr voir le contenu de la collection
 structure JSON du résultat
 en format

db . Etudiants . insertOne ({id_etu: 1, Nom: 'Imen'})

▷ tant que je lui donne pas une clé il génère une clé
 mais id_etu n'est pas traité comme un id
 automatiquement

↓ solution

db . Etudiants . insertOne ({_id: 1, Nom: 'Feten'})

en doit respecter cette
 annotation

► Rq3 chaque document ds mongo db doit avoir obligatoirement un id (si on lui donne pas un id il est généré automatiquement (ObjectId))

► De préférence on laisse mongo db lui-même générer les ids - id de type ObjectId

db.Etudiants.insertOne({Etuid: 2, Nom: 'Walid', adresse: 'Tunis'})


⇒ il accepte des structures ≠ ds une collection

Mongo DB $\leftrightarrow$ BI

DW sur Mongo DB

Rules:

- ① Cardinalité
من 1..n
le nbr de documents
doc simple ou complexe
doc simple ou complexe
- ② MAJ
- ③ Doc Simple ou complexe
- ④ L'accessibilité (le lien métier)
- ⑤ Versionning (yes/no)
لازم نشأه مع ولا مع



des collections
علاقة بين مجموعات

علاقة شكلية

linked

2/ livres (collection principale)




collection embedded
(imbriquée)

Embedded

de préférence on ne dépasse pas le niv 3

Biblio-scénario 1 : validator (Livres, Prix, auteurs, domaine)
Biblio-scénario 2 a : extrême séparation (أبداً معاً)

Livres



extrême incorporation
(أبداً معاً)

Biblio-scénario 2 b :

Livres

↳ Domaine

Auteurs

Maison_Ed

بين البينين

mélange
نفس
suivant les
règles

validator sur le livre

~~titre~~ Prix, titre
auteur, domaine

PFE

Collection
وكان زوزو كان
فكش

validator

Remplir les collections
avec des exemples réels!!

1/ Afficher la liste des produits

use L3DSIG2

db.Produits.find();

2/ Afficher le nbr des produits (documents)
(parlant techniquement)

db.Produits.count();

3/ Afficher les produits de categorie smartphone

db.Produits.find({categorie: 'smartphone'});

ds sql on dit
c'est une
selection

db.Produits.findOne({categorie: 'smartphone'});

// il va selectionner le 1er

4/ Afficher les noms, marques et prix des produits

db.Produits.find({}, {nom: 1, marque: 1, prix: 1});

where
(obligatoire)

↑ projection

5/ Afficher les noms, marques et prix seulement des ordi

db.Produits.find({categorie: 'Ordinateur'},
{_id: 0, nom: 1, prix: 1, marque: 1});

Filter (where)

6/ Les produits qui ont un prix > 1000

db.find({prix: {\$gt: 1000}});

← greater than

projection

7/ Les imprimantes qui ont un prix <= 500

10/ Afficher les produits triés par ordre croissant

db. Product. find(). sort({prix: 1}).

11/ Afficher les prix et les marques des imprimantes triés par prix (ordre décroissant)

db. Product.find({categorie: 'Imprimante'},

{ Marque: 1, Prix: 1}

). sort({Prix: -1}).

12/ Modifier le type 'smartphone' par 'Mobile'

db. Product.updateMany({categorie: 'smartphone'},

{ \$set: {type: 'Mobile'} })


13/ Moyenne des prix des ordinateurs de 20%

Metadata

Le 2^e critère
is la base de
données globale
critère global

TP2 - Rich Document

Rich Document



db.scbd.insertOne ({ scbd_id : 'scbd1',
mem : 'Oracle',
plateforme : ['Microsoft', 'Linux'],
caracteristiques : { date_lancement : **ISOdate**('1977-06-16'),
derniere_version : '23AI',
type : 'Relationnel'
} });

high level field
Array
Record

Afficher les scbd relationnelles:

```
db.scbd.find ( { "caracteristiques.type": "Relationnel" } )
```

Afficher les scbd qui fonctionnent sur MacOS:

```
db.scbd.find ( { plateforme : { $in : ["macOS"] } } )
```

2eme meth avec \$elemMatch:

```
db.scbd.find ( { plateforme : { $elemMatch : { $eq : "macOS" } } } )
```

Ajouter la caractéristique licence avec la valeur commerciale pour le scbd Oracle:

```
db.scbd.updateOne ( { mem : "Oracle",  
{ $set : { "caracteristiques.licence" : "commercial" } } )
```

Afficher les sgbd qui ont été lancés il y a + de 20 ans: Réviser les + fct de type date ds Mongo-DB

```
const now = new Date();  
const twentyYearsAgo = new Date(new Date().getFullYear() - 20);  
db.sgbd.find({  
  "caracteristiques.date_lancement": { $lt: ISODate(twentyYearsAgo.toISOString()) }  
})
```

Afficher les sgbd qui ont été lancés en 1977:

```
db.sgbd.find({  
  "caracteristiques.date_lancement": { $gte: ISODate("1977-01-01"),  
    $lt: ISODate("1978-01-01") }  
})
```

Ajouter un array pr les fonctionnalités de l'sgbd MySQL
Chaque fonctionnalité est caractérisée par un nom, une description et une valeur booléenne pr dire si elle existe ou non

- MySQL a une fonctionnalité ACID → supporte les transactions ACID
- MySQL supporte la réplication → la synchronisation entre 2 bases
- MySQL a un GUI MySQL Workbench
- MySQL ne possède pas une version cloud

(voir tp 2)

TP3: Modelling (suite)

1 écrire une requête qui permet de calculer la moy des prix des livres

```
db.livres.aggregate([
  { $group: {
    _id: null,
    moyenne: { $avg: "$prix" }
  }
}]
```

Les stages:

- \$ group
- \$ sort
- \$ match
- \$ project
- \$ set
- \$ limit
- \$ skip

2 // // // // // des livres français

```
db.livres.aggregate([
  { $match: {
    langue: "français"
  }
  ,
  { $group: {
    _id: null,
    moyenne: { $avg: "$prix" }
  }
}]
```

3 // // // // // des livres par langue

```
db.livres.aggregate([
  { $group: {
    _id: "$langue",
    moyenne: { $avg: "$prix" }
  }
}]
```

TP3: (suite)

4 insérer l'auteur Bill Inmon, Naïven Edition Eyrolles et domaine BI
insérer le livre architecture des entrepôts de données

DBRef
mécanisme de
référencement

au lieu de mettre
l'objet
manuellement

db.lines.insertOne([

edition: { num: 1, année: 2013 }]

~~id: domaine~~

id_auteur: { \$ref: "auteurs",
\$db: "TP3SC1",
\$id: ObjectId("-----")
}

])

TP5: Vues, Index...

* créer une vue livreFr qui renferme les titres, les prix et les types de livres en français

db.createView("livreFr", "livres",

[{ \$match: { langue: "Français" } },

{ \$project: {

_id: 0,

titre: 1,

prix: 1,

type: 1
}

]);

* créer une vue livrePascher qui renferme les titres, les auteurs, les domaines et maison d'éditions des livres qui ont un prix < 100

db.createView("livrePascher", "livres",

[{ \$match: { prix: { \$lt: 100 } } },

\$project: {

_id: 0,

titre: 1,

auteur_id: 1,

maisonEd_id: 1,

domaine_id: 1
}

}

}

}

])

* plan d'exécution d'une requête avec • explain()

permet d'obtenir des informations sur la façon dont une requête est exécutée, y compris les index utilisés, le nb de documents scannés et les étapes du plan d'exécution
=> utile pr analyser les performances des requêtes

- * créer un index sur langue
db.livres.createIndex({langue:1})
- * créer un index sur prix
db.livres.createIndex({prix:1})
- * afficher les index
db.livres.getIndexes();

- * db.livres.find({prix:{<:100}}).explain("executionStats")
← نغول بيش نذرت كفاش
سريع


une BD sans index est très lente
c'est un objet attaché à la collection pr accélérer la recherche

web 3 suis js
Joins 100 2 6
Lollosi 10 10
index


on l'utilise pr prouver qu'on a travaillé sur les BNF performance

Tools (mari)

- Mongo Dump }
- Mongo Restore }
- Mongo Export }
- Mongo Import }



- * Restore Collection
- * Backup d'une collection



- * Export d'une collection
- * Import de la collection

- * Sauvegarder la bd avec l'outil mongodump

```
mongodump --host localhost --db L3DSI2G2 --out C:\BigData
```
- * Restaurer toute collection avec l'outil mongorestore ds une nvlle bd

```
mongorestore --db L3DSI2G2 --copy C:\BigData\L3DSI2G2
```
- * Restaurer une collection avec mongorestore

```
mongorestore --db L3DSI --copy --collection Produits C:\BigData\L3DSI2G2_copy\Produits.Bin
```

base qu'il
 8 3 4 2


base
 8 3 4 2
 Binaire
 json
- * Export d'une collection

```
mongoexport --uri="mongo://localhost/biblio_sc1" --collection=auteurs --out "C:\BigData\auteurs.json"
```
- * Import d'une collection

```
mongoimport --db L3DSI2 --file C:\BigData\C:\BigData\Produits.json
```

optionnel

Windows




lancer la VM

lancer le terminal
Démarrer Hadoop

→ jps
→ start-dfs.sh
→ start-yarn.sh
→ hadoop version

Map Reduce

→ Une technique parmi les techniques de la programmation en parallèle
mais c'est pas un langage mais il travaille avec Java



* Sqoop (بيجي بي دي
ويفر جي بي دي
Hive)


* ETL

* Hbase

* Flume

Pig

* projet p la video
je crée la base hive de Hadoop
et base MySQL de VM et on



Tutorials Point